

U.S. CENSUS BUREAU

BITÁCORA EJECUTIVA DEL PIPELINE MLOps

★ ★ ADULT CENSUS INCOME 1994 ★ ★

PREDICCIÓN DE INGRESO > US\$50K

DE LOS DATOS AL SISTEMA PREDICTIVO



Documentamos nuestro recorrido para construir un sistema MLOps completo: desde la comprensión del negocio y los datos hasta el despliegue y monitoreo de un modelo confiable, reproducible y auditable.



COMPRENDER
el pasado y los datos



CONSTRUIR
el sistema



DEMOSTRAR
valor real



PROYECTO INTEGRADOR
Ciencia de Datos e IA
2026



EQUIPO
Grupo 2



PROPÓSITO
Alinear • Planificar •
Construir juntos



ENFOQUE
Datos con contexto,
ética y resultados

“ Datos sobre personas.
Historia que explica.
Decisiones que transforman. ”

COLLECTION YEAR

1994



DATOS

Adult Census Income
(Censo 1994 - EE. UU.)



**ANÁLISIS ORIENTADO
A DECISIONES**

Cada análisis aporta
una decisión.




PIPELINE MLOps

Reproducible, versionado
y automatizable.



**CONFIABLE
Y AUDITABLE**

Ética, transparencia
y trazabilidad.





CÓMO TRABAJAMOS

Colaboramos en ciclos iterativos. Cada uno lidera por etapas y todos participamos en todo el proceso.

1. LIDERA Y CONSTRUYE

Toma la iniciativa de la etapa asignada, propone soluciones, construye y genera avances de calidad.

- Toma la iniciativa
- Construye soluciones
- Documenta decisiones
- Genera avance

2. REVISY ENRIQUECE

Revisa críticamente lo construido, aporta ideas, detecta riesgos, sugiere mejoras y eleva la calidad del trabajo.

- Revisa con criterio
- Aporta ideas y mejoras
- Detecta riesgos y sesgos
- Refina y fortalece

3. INTEGRA Y DA CONTINUIDAD

Integra lo validado, documenta lo clave, prueba y asegura que el avance quede listo para la siguiente iteración.

- Integra lo validado
- Prueba y verifica
- Documenta y registra
- Prepara para continuar

TODOS PARTICIPAMOS EN TODO EL CICLO
Transparencia, respeto y compromiso.

ÁMBITOS QUE IREMOS LIDERANDO



DATOS Y CALIDAD

Entender y preparar los datos.

- Ingesta y calidad de datos
- Exploración y limpieza
- Diccionario y documentación
- Gobierno y trazabilidad



ANÁLISIS Y MODELADO

Entender, modelar y aprender.

- EDA profundo y visualización
- Feature Engineering
- Modelos y evaluación
- Validación cruzada y fairness



SISTEMA MLOps

Convertir modelos en valor real.

- Experimentos y registro (MLflow)
- Despliegue (API / Serving)
- Monitoreo y drift
- Alertas y mejora continua



Los ámbitos se lideran por etapas. Los roles rotan según la necesidad y el avance del proyecto.

ACUERDOS Y PRINCIPIOS QUE NOS GUÍAN



TRANSPARENCIA

Decisiones y avances visibles para todos.



DOCUMENTACIÓN

Todo lo importante queda registrado para aprender y replicar.



REVISIÓN CRUZADA

Nos revisamos con respeto para elevar la calidad del trabajo.



ENFOQUE EN VALOR

Todo lo que hacemos debe acercarnos al objetivo del proyecto.



ÉTICA Y RESPONSABILIDAD

Buscamos modelos justos, con impacto responsable y consciente.



ARQUITECTURA, REPOSITORIO E INGESTA

Base del proyecto: datos reproducibles, código versionado y pipeline de MLOps

U.S. CENSUS BUREAU

COLLECTION YEAR

1994




FLUJO GENERAL DEL PROYECTO



ESTRUCTURA DEL REPOSITORIO

grupo2-aci94-mlops



¿PARA QUÉ EXISTE CADA CARPETA?

- Almacenamiento de datos en cada etapa del pipeline.
- Análisis, EDA, modelado y documentación del proyecto.
- Código fuente modular y reutilizable (scripts, funciones, pipelines).
- Pruebas unitarias y de integración.
- Documentación, guías y reportes.
- Dependencias y configuraciones.

PROCESO DE INGESTA REPRODUCIBLE



PRINCIPIOS DE DISEÑO

- ✓ Reproducibilidad: siempre desde la fuente oficial.
- ✓ Automatización: sin intervención manual.
- ✓ Trazabilidad: logs y estructura clara.
- ✓ No versionamos datos, versionamos código.

TECNOLOGÍAS Y HERRAMIENTAS




GOBERNANZA Y BUENAS PRÁCTICAS



EN RESUMEN

Esta arquitectura asegura que el proyecto sea reproducible, colaborativo y escalable, sentando las bases para un flujo de MLOps completo y confiable.

ROADMAP DEL PROYECTO



DATOS SOBRE PERSONAS. HISTORIA QUE EXPLICA. PATRONES QUE AYUDAN A DECIDIR. MODELOS QUE GENERAN VALOR.

DATA QUALITY
DEL DATO CRUDO AL DATO CONFIABLE

U.S. CENSUS BUREAU

COLLECTION YEAR

1994



GRUPO 2 · EQUIPO DEL PROYECTO

Naomy Alvarado Zúñiga | Dalay Sánchez Brenes | Vladímir Marín Durán



NUESTRO OBJETIVO

Asegurar que los datos sean completos, consistentes y listos para responder preguntas de negocio y construir modelos confiables.



EN NÚMEROS

- ✓ Registros iniciales (RAW): 48.842
- ✓ Registros finales (CLEAN): 48.790
- ✓ Variables: 15 (14 predictoras + 1 target)
- ✓ Duplicados conocidos eliminados: 29
- ✓ Reglas aplicadas: 10

EVALUACIÓN DE REGLAS

RAW: 5 PASS
3 WARNING
0 FAIL

CLEAN: 7 PASS
0 WARNING
0 FAIL

PRINCIPIOS QUE GUIARON NUESTRAS DECISIONES



1. NO LIMPIAR POR REFLEJO

Primero interpretamos los datos antes de decidir qué hacer.



2. DUPLICADO ≠ PERSONA DUPLICADA

Sin identificador individual, la decisión se toma con criterio y transparencia.



3. EXTREMO + ERROR

Valores altos o poco frecuentes pueden ser plausibles y contener señal importante.



4. DECISIONES DOCUMENTADAS

Cada tratamiento queda justificado para asegurar trazabilidad y replicabilidad.



5. PENSAR EN EL MODELO

Lo que hoy es un hallazgo, mañana puede ser una decisión de modelado.

NUESTRO CAMINO: DEL DATO CRUDO AL DATO CONFIABLE

1. ENTRADA (RAW)

48.842
registros
15 variables

5 PASS - 3 WARNING - 0 FAIL

2. DIAGNÓSTICO



- Faltantes
- Tipos de datos
- Valores atípicos
- Valores extremos
- Duplicados
- Consistencia de categorías



3. LIMPIEZA Y TRATAMIENTO



- Tratamiento de faltantes conocidos
- Estandarización de categorías en target ($\leq 50K$ / $> 50K$)
- Eliminación de duplicados definidos
- Conversión y validación de tipos
- Conservación de valores extremos plausibles



4. VALIDACIÓN FINAL



- Re-ejecución de reglas
- Verificación de consistencia
- Validación de resultados



5. SALIDA (CLEAN)

48.790
registros
15 variables

7 PASS - 0 WARNING - 0 FAIL



DECISIONES QUE YA QUEDAN SUSTENTADAS

- ✓ No se eliminaron registros por faltantes cuando existía un tratamiento o imputación razonable.
- ✓ Se reemplazaron símbolos "?" por "Unknown" de forma consistente en variables categóricas.
- ✓ Se estandarizaron las etiquetas del target ($\leq 50K$ / $> 50K$) para un análisis unificado.
- ✓ Se eliminaron 29 duplicados conocidos de manera justificada.
- ✓ Se conservaron valores extremos plausibles por su posible valor predictivo.

LO QUE DATA QUALITY LE PREGUNTA AL EDA



¿Qué explica el desbalance 76.2% / 23.8% para el entrenamiento y la evaluación?



¿Education y education-num aportan información redundante o complementaria?



¿Qué señal contienen capital-gain, capital-loss y cómo se relacionan con income?



¿Los valores extremos observados cambian patrones o requieren tratamientos específicos?



¿Existen categorías pequeñas o raras que puedan afectar la generalización?



LO QUE AÚN NO DEBEMOS DECIDIR

- Que una variable extrema deba eliminarse solo por ser extrema.
- Que una asociación observada implique causalidad.
- Qué predictor conservar únicamente por intuición.
- Qué transformación usar antes de estudiar su relación con income.



PRINCIPIO APRENDIDO

Comprender el significado del dato antes de transformarlo.

Especialmente en un dataset histórico (1994): un valor poco común no es automáticamente un error.

PUENTE HACIA EL EDA

DATO
CONFIABLE

HALLAZGO

INTERPRETACIÓN
¿QUÉ SIGNIFICA?DECISIÓN
¿QUÉ CAMBIA?

PRÓXIMO PASO

Exploraremos los datos con propósito, respondiendo a estas preguntas para tomar decisiones de modelado informadas.

DATA QUALITY → EDA → FEATURE ENGINEERING



EDA – ADULT CENSUS INCOME 1994

ANÁLISIS EXPLORATORIO ORIENTADO A DECISIONES

U.S. CENSUS BUREAU

COLLECTION YEAR
1994

CONTEXTO DEL DATASET


Encuesta de ingresos de adultos en EE. UU. (Censo 1994)
Predicción: ingreso anual > US\$50K

Datos de 1994


Interpretar en su contexto
histórico y socialVISIÓN GENERAL
DEL DATASET48,790
Registros15
Variables76.2% / 23.8%
≤50K / >50K
(Desbalance de clases)0
Valores faltantes

1. DISTRIBUCIONES CLAVE


Ingreso (variable objetivo)

■ ≤50K (76.2%)
■ >50K (23.8%)

Edad

Rango: 17 – 90 años
Media: 38.6 | Mediana: 36
Concentración entre
25 y 50 años

Horas trabajadas por semana

Rango: 1 – 99 horas
Media: 40.4 | Mediana: 40
Mayoría entre 35 y 60 horas

2. RESUMEN DE VARIABLES IMPORTANTES



education / education-num

Muy alta correlación ($r \approx 0.81$).
education-num es la versión numérica.
DECISIÓN: usar education-num para modelado.

capital-gain / capital-loss

Muchos ceros pero con valores altos en algunos casos.
Aportan información relevante sobre ingreso.
DECISIÓN: mantener ambas variables.

fnlwgt

Peso muestral, no es un identificador.
DECISIÓN: usar como peso en modelos y métricas.workclass, occupation,
native-countryCategorías con baja representación en algunos niveles.
DECISIÓN: agrupar categorías raras en "Other".

sex, race

Presentan diferencias en ingreso.
DECISIÓN: considerar para análisis AND
evaluar impacto de sesgo (fairness).

relationship, marital-status

Relacionadas con estructura familiar y potencial ingreso.
DECISIÓN: mantener para modelado.

3. RELACIONES CLAVE CON EL INGRESO (>50K)



education-num

A mayor nivel educativo,
mayor probabilidad de >50K. ↑

capital-gain

Quienes reportan ganancias de capital
tienen mayor probabilidad de >50K. ↑

hours-per-week

Más horas trabajadas se asocian
con mayor probabilidad de >50K. ↑

occupation

Algunas ocupaciones tienen
mayor concentración de >50K
(ej. Exec-managerial, Prof-specialty). ↑

race, sex

Se observan diferencias en ingreso
entre grupos.
(Requiere análisis de fairness) =

4. CALIDAD DE LOS DATOS

- ✓ Sin valores faltantes en ninguna variable.
- ✓ Consistencia de tipos de datos: OK.
- ✓ Valores atípicos esperados en variables como capital-gain, capital-loss y fnlwgt.
- ✓ Desbalance de la variable objetivo: 76.2% vs 23.8%.

IMPLICACIÓN

Considerar métricas
apropiadas (AUC, F1,
Recall, Precision)
y técnicas de manejo
de desbalance.

5. DECISIONES CLAVE DEL EDA

- ✓ Usar education-num (menos redundante).
- ✓ Mantener capital-gain y capital-loss.
- ✓ Usar fnlwgt como peso.
- ✓ Agrupar categorías poco frecuentes en variables categóricas.
- ✓ Incluir análisis de fairness por grupos sensibles.
- ✓ Evaluar modelos con métricas robustas al desbalance.



6. RIESGOS Y CONSIDERACIONES

- ⚠ Datos de 1994 → reflejan contexto social, económico y legal de esa época.
- ⚠ Posibles sesgos históricos en variables sensibles (sex, race, native-country).
- ⚠ Riesgo de sobreajuste si se usan muchas variables con poca señal.
- ⚠ No asumir causalidad en las asociaciones observadas.

PRÓXIMOS PASOS
DEL PROYECTO

1. FEATURE ENGINEERING

- Codificación de variables
- Agrupación de categorías raras
- Transformaciones necesarias



2. MODELADO

- Modelos baseline
- Comparación de algoritmos



3. EVALUACIÓN

- Validación cruzada
- Métricas enfocadas en desbalance y fairness



4. EXPERIMENTACIÓN (MLFLOW)

- Registro de experimentos
- Parámetros, métricas y modelos
- Selección del mejor modelo



5. DESPLIEGUE

- API
- Docker
- Monitoreo



DATOS SOBRE PERSONAS. HISTORIA QUE EXPLICA. PATRONES QUE AYUDAN A DECIDIR. MODELOS QUE GENERAN VALOR.

★★★ CENSUS 94 ★★★

FEATURE ENGINEERING
DEL DATO EN BRUTO A VARIABLES QUE ENSEÑAN

Transformamos los datos crudos en representaciones numéricas informativas, estables y libres de sesgos que permiten al modelo aprender patrones reales y generalizar mejor.

U.S. CENSUS BUREAU

COLLECTION YEAR

1994

¿POR QUÉ ESTA ETAPA ES CLAVE?



- Representar la realidad de forma útil para el algoritmo
- Reducir ruido y ambigüedad
- Evitar fuga de información (leakage)
- Garantizar reproducibilidad y trazabilidad

1. PUNTO DE PARTIDA
DEL DATASET

Dataset Adult Census
Income (1994)
15 columnas:
14 predictoras +
1 objetivo (income)
>50K vs ≤50K

VARIABLES ORIGINALES (15)

- age, workclass, fnlwgt, education,
- education-num, marital-status,
- occupation, relationship, race,
- sex, capital-gain, capital-loss,
- hours-per-week, native-country,
- income (objetivo)

2. DECISIONES CLAVE
PARA NUESTRA VERSIÓN PRODUCTIVA

Exclusión de variables sensibles:
sex, race y native-country se excluyen en v2_without_sensitive para reducir exposición a atributos sensibles.



Redundancia:
education se excluye por alta redundancia con education-num.



Peso muestral:
fnlwgt no se utiliza como predictora (peso de encuesta, no identificador).



Objetivo binario:
income recodificado en >50K (1) vs ≤50K (0).

3. TRANSFORMACIONES IMPLEMENTADAS
EN EL PIPELINE (scikit-learn)

Numéricas:

- Imputación: mediana (estrategia robusta)
- Escalado: StandardScaler (media 0, varianza 1)



Categorías nominales:

- OneHotEncoder (drop = first)
- Manejo de categorías desconocidas: handle_unknown = 'ignore'



Variables con asimetría fuerte:

- capital-gain y capital-loss
- Indicador binario (flag > 0) + transformación logarítmica: log1p(valor) para valores > 0; 0 en caso contrario (reduce sesgo y estabiliza varianza).



Pipeline completo:

todas las transformaciones encapsuladas en un Pipeline único para garantizar consistencia entre entrenamiento y producción.

4. COMPARATIVO DE VERSIONES Y VARIABLES

VERSIONES CONSTRUIDAS

v1_baseline
(experimentación)

Incluye todas las variables
no excluidas por calidad.

v2_without_sensitive
(productiva)

Excluye variables sensibles:
sex, race, native-country.



Versión productiva utilizada en el modelo final:
v2_without_sensitive

v2_without_sensitive
VARIABLES UTILIZADAS (9)

Numéricas (5)

- age
- education-num
- hours-per-week
- capital-gain (transformada)
- capital-loss (transformada)

Categorías (4)

- workclass
- marital-status
- occupation
- relationship

5. PIPELINE DE FEATURE ENGINEERING (FLUJO GENERAL)



Datos crudos
15 variables



Limpieza y
normalización
(ver Data Quality)



Selección de variables
(criterios definidos)



Transformaciones
en Pipeline
(imputación, codificación,
escalado, log, flags)



Dataset final
v2_without_sensitive
9 variables predictoras
+ 1 objetivo



Listo para
modelado
sin fuga de información
y reproducible

DISTRIBUCIÓN EN v2_without_sensitive

Numéricas (5)

age
education-num
hours-per-week
capital-gain (log + flag)
capital-loss (log + flag)



Categorías (4)

workclass
marital-status
occupation
relationship



Total final: 9 variables predictoras + 1 objetivo

IMPACTO DE LAS TRANSFORMACIONES



- Datos coherentes y comparables
- Menor ruido y mayor estabilidad numérica
- Prevención de overfitting y de fuga de información
- Representación justa y responsable
- Preparación óptima para evaluar modelos

MODELADO Y EVALUACIÓN
ELEGIR EL MODELO QUE GENERALIZA MEJOR

Evaluamos varios algoritmos con validación cruzada estratificada para datos desbalanceados y métrica principal G-Mean (balance entre Recall y Specificity). Se seleccionó el modelo que mejor combina sensibilidad, especificidad y estabilidad de generalización.



¿POR QUÉ ESTA ETAPA ES CLAVE?



- Elegir el algoritmo que mejor aprende patrones reales.
- Evitar sobreajuste (overfitting).
- Evaluar desempeño con métricas apropiadas para clases desbalanceadas.
- Seleccionar el modelo que aporta más valor y es estable.

1. CONFIGURACIÓN DE EXPERIMENTOS



Validación cruzada estratificada
StratifiedKFold
5 folds, shuffle=True, random_state=42



Métrica principal
G-Mean (media geométrica de
Recall y Specificity).
Detecta positivos y evita falsos positivos.



Métricas complementarias
Recall, Specificity, F1-score y ROC AUC.




Pipeline único de preprocesamiento
Todas las transformaciones se aplican dentro
del CV para evitar fuga de información.

2. COMPARACIÓN DE ALGORITMOS (RESULTADOS PROMEDIO EN TEST)

Modelo	Features	G-Mean (↑ mejor)	Recall (↑ mejor)	Specificity (↑ mejor)	F1-score (↑ mejor)	ROC AUC (↑ mejor)	Observación
Random Forest (class_weight="balanced")	v2_without_sensitive	0.8374	0.8660	0.8098	0.7011	0.9219	Mejor balance entre sensibilidad y especificidad. Alta estabilidad. ★
Random Forest (sin class_weight)	v2_without_sensitive	0.8253	0.8421	0.8097	0.6750	0.9156	Desempeño cercano, pero menor Recall.
Árbol de Decisión (sin balanceo)	v2_without_sensitive	0.7480	0.7469	0.7491	0.5652	0.8114	Mayor tendencia a sobreajuste.
Regresión Logística (class_weight="balanced")	v2_without_sensitive	0.7256	0.7811	0.6758	0.5853	0.8401	Buen Recall, menor Specificity.
Dummy Classifier (mayoría)	v2_without_sensitive	0.0000	0.0000	1.0000	0.0000	0.5000	Referencia mínima (sin aprendizaje).

✓ Modelo seleccionado: Random Forest con class_weight="balanced" y features v2_without_sensitive.

3. ESTABILIDAD DEL MODELO (CV)



✓ El modelo muestra buena estabilidad y baja variabilidad entre folds.

4. HIPERPARÁMETROS DEL MODELO FINAL



Algoritmo: Random Forest Classifier
class_weight = "balanced"

n_estimators 150
max_depth 20
min_samples_split 5
min_samples_leaf 2
max_features "sqrt"
bootstrap True
random_state 42



Configuración almacenada y registrada en MLflow
para reproducibilidad del experimento.

5. VALIDACIÓN FINAL EN CONJUNTO TEST (HOLD-OUT 20%)

MÉTRICAS FINALES - RANDOM FOREST
(v2_without_sensitive)

🔧 G-Mean:	0.8374
📊 Recall (Sensibilidad):	0.8660
⚙️ Specificity:	0.8098
📈 F1-score:	0.7011
✓ ROC AUC:	0.9219

Diferencia absoluta
Validación vs Test (G-Mean): ≈ 0.0036


Resultados finales sobre el conjunto completamente no visto.

MATRIZ DE CONFUSIÓN - TEST

	Predicho	
	0 (≤50K)	1 (>50K)
0 (≤50K)	8,876 (TN)	2,111 (FP)
1 (>50K)	1,647 (FN)	10,573 (TP)

G-Mean combina Recall y Specificity
para balancear ambos tipos de error.

CURVA ROC - TEST



6. DECISIONES TOMADAS

- ✓ Se priorizó G-Mean para optimizar el balance entre Recall y Specificity en datos desbalanceados.
- ✓ Random Forest con class_weight="balanced" obtuvo el mejor conjunto de métricas y estabilidad.
- ✓ Se usó la versión v2_without_sensitive (sin variables sensibles) como base productiva.
- ✓ No hay evidencia de sobreajuste significativo (brecha Validación-Test de G-Mean ≈ 0.0036).
- ✓ El modelo queda listo para registrarse en MLflow como Production Candidate.



SIGUIENTE ETAPA

Registrar el experimento seleccionado en MLflow, promoverlo a Candidate y luego a Production. Continuaremos con el serving (FastAPI + Docker).

MLflow Y REGISTRY
DEL EXPERIMENTO AL MODELO EN PRODUCCIÓN

Registramos y gestionamos los experimentos, comparamos modelos y versionamos el artefacto seleccionado para asegurar trazabilidad, reproducibilidad y control de despliegue.



¿POR QUÉ ESTA ETAPA ES CLAVE?



- Trazabilidad total de experimentos.
- Comparar modelos y métricas de forma objetiva.
- Versionar el mejor modelo y promoverlo.
- Garantizar reproducibilidad en producción.

1. EXPERIMENTOS REGISTRADOS EN MLflow



Se registraron experimentos comparando algoritmos, configuraciones y conjuntos de variables (v1_baseline y v2_without_sensitive).



Experimentos registrados: -- NA*



Runs totales: -- NA*



Parámetros registrados: -- NA*



Métricas monitoreadas: -- NA*

MODELOS EVALUADOS

(ejemplos de algoritmos probados)

- ✓ Random Forest (con / sin balanceo)
- ✓ Regresión Logística (con / sin balanceo)
- ✓ Árbol de Decisión (con / sin balanceo)
- ✓ Dummy Classifier (mayoría)
- ✓ Otros experimentos y configuraciones



* El historial original de MLflow (mlflow.db y mlartifacts) no está disponible actualmente en nuestro entorno local. La reconstrucción histórica estricta se encuentra pendiente. El artefacto del modelo en producción sí está disponible y versionado correctamente.

2. COMPARACIÓN Y SELECCIÓN DEL MODELO

CRITERIOS DE SELECCIÓN

- ✓ Maximizar G-Mean (balance entre Recall y Specificity)
- ✓ Estabilidad entre folds (baja variabilidad)
- ✓ Buen desempeño en métricas complementarias (F1, ROC AUC)
- ✓ Simplicidad y costo computacional razonable

MODELO SELECCIONADO



Random Forest

class_weight="balanced"

Features: v2_without_sensitive

MÉTRICAS FINALES (TEST) – MODELO SELECCIONADO

G-Mean (↑ mejor)	Recall (↑ mejor)	Specificity (↑ mejor)	F1-score (↑ mejor)	ROC AUC (↑ mejor)
0.8374	0.8660	0.8098	0.7011	0.9219



El mejor balance entre sensibilidad y especificidad con alta estabilidad y excelente capacidad de generalización.

3. REGISTRO DEL MODELO Y VERSIONADO

Modelo registrado:

adult-income-classifier

Fecha de registro:
31/08/2026Versión registrada:
1Etapa inicial:
CandidateFramework:
scikit-learn

Descripción: seleccionado para predicción de ingreso > \$50K con features v2_without_sensitive.

FLUJO DE VERSIONADO (ALÍAS)



El registro y versionado se realizan mediante alias en MLflow Model Registry: Candidate → Validation → Production.

4. ARTEFACTOS DEL MODELO EN PRODUCCIÓN (v1)



Artefacto registrado en MLflow Model Registry – Production (v1).

Ruta del modelo:

models/adult-income-classifier/Production

CONTENIDO DEL
ARTEFACTOTAMAÑO
(bytes)

modelo.pkl	35,570,826 (~34 MB)
MLmodel	1,764
conda.yaml	3,457
requirements.txt	206
python_env.yaml	3,327



El artefacto incluye el modelo entrenado y la configuración necesaria para reproducir predicciones en producción.

5. TRAZABILIDAD Y REPRODUCIBILIDAD



Cada experimento registra: parámetros, métricas, código y artefactos asociados.



El modelo está versionado y promovido a Production (v1).



El artefacto es reproducible: mismas dependencias y mismo ambiente.



Reproducibilidad histórica de runs: pendiente de restauración del backend de MLflow.

¿QUÉ PERMITE MLflow?

- Conocer exactamente qué se entrenó, cuándo y con qué.
- Comparar desempeño entre modelos de forma objetiva.
- Promover con control y trazabilidad el mejor modelo.
- Asegurar consistencia entre entrenamiento y producción.

6. RESUMEN DE ESTA ETAPA

- ✓ Se ejecutaron múltiples experimentos y se compararon algoritmos con validación cruzada estratificada (5-Fold).
- ✓ Random Forest con class_weight="balanced" y features v2_without_sensitive fue el modelo seleccionado.
- ✓ El modelo se registró como adult-income-classifier, versión 1, etapa Candidate y se promovió a Production.
- ✓ El artefacto en Production (v1) está disponible y listo para ser consumido por la API.
- ✓ La trazabilidad y reproducibilidad quedan aseguradas para el despliegue en cualquier entorno.

09

BITÁCORA EJECUTIVA
DEL PIPELINE MLOps ★ ★ ★

GRUPO 2 • EQUIPO ACI94-ML

Naomy Alvarado Zuñiga | Dalay Sánchez Brenes | Vladimir Marín Durán

SERVING: API, DOCKER Y PREDICCIÓN
DEL MODELO A UNA PREDICCIÓN REALPonemos nuestro modelo **Production v1** en producción con una API robusta,
contenedorizada y consumida por una interfaz web.

★ ★ ★

U.S. CENSUS BUREAU

COLLECTION YEAR

1994

**MODELO UTILIZADO**
adult-income-classifier
Production v1
(Random Forest)**ENTRADAS DEL MODELO**
9 variables de entrada
(v2_without_sensitive)
Contrato fijo de la API**VALIDACIÓN**
Esquema con Pydantic
(tipos y rangos)
Datos consistentes y seguros**TECNOLOGÍA**
FastAPI · Python
scikit-learn · joblib
Uvicorn**DESPLIEGUE**
Docker
Imagen ligera y
reproducible**PRUEBAS**
37 tests
automatizados
aprobados

1

API FASTAPI

Servicio de predicción



- Endpoint principal: POST /predict
- Carga el modelo Production v1 al iniciar
- Validación de entrada con Pydantic
- Respuesta JSON con predicción, probabilidad y versión del modelo

ENDPOINTS DISPONIBLES

GET	/health	→	Estado del servicio
POST	/predict	→	Realiza predicción
GET	/model-info	→	Información del modelo
GET	/metrics	→	Métricas del servicio

2

INTERFAZ STREAMLIT

Experiencia del usuario



- Interfaz amigable para el usuario final
- Envía los datos a la API FastAPI
- Muestra la predicción y la probabilidad devuelta por el modelo

FLUJO DE USO

- 1 Usuario ingresa los 9 valores solicitados
- 2 Streamlit envía los datos a la API
- 3 API valida, predice y responde
- 4 Streamlit muestra el resultado

3

DOCKER: CONTENEDOR DEL SERVICIO

Portabilidad y reproducibilidad



El contenedor incluye:

- ✓ FastAPI (servicio)
- ✓ Modelo Production v1 (snapshot versionado)
- ✓ Dependencias del proyecto

COMPONENTES DEL CONTENEDOR

- Python 3.11
- FastAPI + Uvicorn
- scikit-learn
- joblib (carga del modelo)
- Dependencias (requirements.txt)

4

PRUEBAS AUTOMATIZADAS

Calidad y confianza

**37 tests
automatizados
aprobados**

COBERTURA DE PRUEBAS

- ✓ Validación de entrada (Pydantic)
- ✓ Lógica de predicción
- ✓ Manejo de errores
- ✓ Endpoints: /health, /predict, /model-info, /metrics

EJECUCIÓN REAL (PYTEST)

```
===== test session starts =====
collected 37 items
..... 37 passed
===== 37 passed in 116.54s =====
```

CONTRATO DEL MODELO ENA PRODICCIÓN

El modelo Production v1 espera
exactamente 9 variables de entrada:

✓ age

✓ education-num

✓ hours-per-week

✓ workclass

✓ marital-status

✓ occupation

✓ relationship

✓ capital-gain

✓ capital-loss

No se incluyen variables sensibles: race, sex, native-country.

FLUJO END-TO-END DE UNA PREDICCIÓN REAL



USUARIO

Ingresa los 9 valores
en la interfaz Streamlit

STREAMLIT

Envía los datos
a FastAPI (/predict)

FASTAPI

Valida entrada
y ejecuta predicción
con Production v1MODELO
PRODUCTION V1Random Forest
(snapshot versionado)

RESPUESTA JSON

Devuelve:

- prediction
- probability
- model_version



RESULTADO

Mostrado al usuario
en Streamlit

BENEFICIO LOGRADO

Servicio robusto, reproducible y validado que permite
entregar predicciones confiables a los usuarios.

Confiable

Validación estricta
de datos

Reproducible

Docker garantiza
mismo entorno

Probado

37 tests
aprobadosListo para
el usuario finalPaso clave hacia
un MLOps completo

MONITORING Y DRIFT
DEL MODELO DESPLEGADO AL MODELO VIGILADOMonitoreamos continuamente la calidad de los datos, el drift, el desempeño del modelo
y la salud del servicio para tomar decisiones oportunas.

U.S. CENSUS BUREAU

COLLECTION YEAR

1994

1 DATA QUALITY MONITORING



Contrato de datos (9 variables)

Validamos que cada lote cumpla
con el contrato esperado.

BLOCK

Errores críticos que impiden continuar.



WARN

Incidencias que no bloquean el proceso.

Variables monitoreadas: age, education-num, hours-per-week,
workclass, marital-status, occupation, relationship,
capital-gain, capital-loss.

* Lote ejecutado para validar el sistema de monitoreo. No corresponde a tráfico real de producción.

EJECUCIÓN MÁS RECIENTE*

Ejecución completada
(lote contaminado)

Resultado:

6 incidencias
detectadas

3 BLOCK | 3 WARN

El sistema continuó el flujo.

2 DRIFT DETECTION (PSI) ★★☆☆



PSI

Medimos el cambio en la
distribución entre datos
de referencia y nuevos
lotes usando PSI.

Variables monitoreadas

- age
- education-num
- hours-per-week
- occupation

RANGOS PSI

0.00 – 0.10 OK
Sin drift significativo0.10 – 0.25 WARNING
Drift moderado> 0.25 ALERT
Drift fuerteDetectar drift nos permite anticiparnos a la degradación
del modelo y tomar acciones oportunas.

3 EVIDENCIA DE DRIFT (PSI)

LOTE SIMULADO*	FECHA	PSI PROMEDIO	ESTADO	INTERPRETACIÓN
Lote 1 (sin drift)	2025-09-01	0.0027	OK	Distribución estable. Sin cambio relevante.
Lote 2 (drift moderado)	2025-09-01	0.1529	WARNING	Cambio moderado. Monitoreo reforzado.
Lote 3 (drift fuerte)	2025-09-01	3.6700	ALERT	Cambio fuerte. Riesgo alto para el desempeño del modelo.

* Lotes generados con datos simulados para validar el sistema de monitoreo.
No corresponden a tráfico real de producción.

4 MODEL PERFORMANCE MONITORING

Evaluamos el desempeño del modelo
en lotes de datos etiquetados para
detectar degradación.

Métrica principal: G-Mean

BASELINE
PRODUCTION v1
(Validación/Test)

0.8374

LOTE ETIQUETADO*	FECHA	G-MEAN	ESTADO
Lote estable (simulado)	2025-09-01	0.8000	OK
Lote degradado (simulado)	2025-09-01	0.4899	ALERT

* Lotes etiquetados simulados para demostrar el sistema de evaluación.
No corresponden a tráfico real de producción.

5 SYSTEM METRICS (SALUD DEL SERVICIO)

Monitoreamos la salud del servicio expuesto
en el endpoint /metrics.
Estas métricas se actualizan en tiempo real.

MÉTRICAS DISPONIBLES VÍA /METRICS

- ✓ Uptime del servicio
- ✓ Total de requests
- ✓ Requests exitosas
- ✓ Requests con error
- ✓ Error rate (%)
- ✓ Throughput (req/min)
- ✓ Average latency (ms)
- ✓ Last latency (ms)

Monitoreamos continuamente la disponibilidad, carga
y latencia del servicio para asegurar una experiencia confiable.

6 DECISIÓN: ¿QUÉ HACEMOS?



MANTENER

- PSI OK (≤ 0.10)
- Desempeño estable (cercano al baseline)
- Sistema saludable

Continuamos
monitoreando.

REVISAR

- PSI WARNING (0.10 – 0.25) y/o
- Caída moderada en desempeño
- Incremento de errores o latencia

Investigamos,
ajustamos y
seguimos
monitoreando.CONSIDERAR
REENTRENAMIENTO

- PSI ALERT (> 0.25) y/o
- Degradación significativa del
desempeño
- Problemas persistentes en el servicio

Preparamos
reentrenamiento
y nueva versión.

Decisiones basadas en evidencia para proteger el valor del modelo en producción.



BENEFICIO LOGRADO

Detectamos problemas a tiempo,
prevenimos degradación y aseguramos
un servicio confiable y disponible.Calidad de datos
monitoreadaDrift detectado
continuamenteDesempeño bajo
vigilanciaServicio saludable
y disponibleDecisiones oportunas
para el negocio

DATOS SOBRE PERSONAS, HISTORIAS QUE EXPLICAN, PATRONES QUE AYUDAN A DECIDIR, MODELOS QUE GENERAN VALOR.


ARQUITECTURA MLOps INTEGRAL Y CIERRE
DEL EXPERIMENTO A PRODUCCIÓN CON MONITOREO CONTINUOResumen de nuestra arquitectura end-to-end y del recorrido completo
que transforma datos en decisiones de negocio con confianza.

U.S. CENSUS BUREAU


COLLECTION YEAR

1994

1 ARQUITECTURA MLOps — VISTA END-TO-END



2 MONITOREO CONTINUO (IMPLEMENTADO)



3 STACK TECNOLÓGICO



4 RECORRIDO COMPLETO — DEL DATO A LA DECISIÓN



BENEFICIO LOGRADO

Transformamos datos históricos en inteligencia accionable con un sistema MLOps confiable, auditable y escalable en el tiempo.

Confianza
Calidad y validación
en cada paso.Reproducibilidad
End-to-end desde datos
hasta producción.Monitoreo continuo
Detectamos y actuamos
a tiempo.Servicio confiable
API saludable,
impulsar el disponible.CENSUS 94
★★★☆☆