

CANVAS INICIAL – PROYECTO ML

PREDICCIÓN DE INGRESO > US\$50K



Nuestro objetivo:
Predecir si una persona tiene
ingreso anual mayor a US\$50.000

1. CONTEXTO DEL NEGOCIO

El problema que buscamos resolver
no es técnico, es de negocio:

¿Qué características socioeconómicas
y laborales permiten identificar patrones
asociados con personas cuyos ingresos
anuales superan los US\$50.000?

Datos históricos del Censo de EE. UU. (1994)
para comprender patrones de ingreso.

Aplicable a análisis socioeconómico,
educación, empleo y políticas públicas.

El modelo debe ser útil, interpretable
y evaluado con responsabilidad.

2. DATASET EN RESUMEN

Adult Dataset – UCI Machine Learning Repository
Extraído por Barry Becker (1994)

- Total registros: 48.842
 - Entrenamiento (adult.data): 32.561
 - Prueba (adult.test): 16.281
- Variables: 14 predictoras + 1 objetivo
- Tipo de problema: Clasificación binaria
- Fuente: Censo de EE. UU. 1994

Condiciones de extracción:
(AAGE > 16) && (AGI > 100) &&
(AFNLWGT > 1) && (HRSWK > 0)

Representa a población adulta con
determinadas condiciones de participación
económica/laboral (no es toda la población).


3. OBJETIVO ML

Predecir si el ingreso anual
de una persona es:

0 vs. **1**
≤ US\$50K > US\$50K

Detalles clave:

- >50K corresponde aprox. al 23,93%
- ≤50K corresponde aprox. al 76,07%
- Tenemos una clase minoritaria (desbalance)
- Accuracy sola NO será suficiente.
- Usaremos métricas como Precision, Recall, F1, ROC-AUC, matriz de confusión, etc.



4. LAS 14 VARIABLES PREDICTORAS

Dimensión	Variable	¿Qué representa?
Demográfica	age	Edad
Laboral	workclass	Tipo de empleador / actividad
Poblacional	fnlwgt	Peso estadístico del registro (final weight)
Educativa	education	Nivel educativo
Educativa	education-num	Nivel educativo codificado numéricamente
Familiar	marital-status	Estado civil
Laboral	occupation	Ocupación
Familiar	relationship	Relación dentro del hogar
Demográfica	race	Raza registrada
Demográfica	sex	Sexo
Económica	capital-gain	Ganancias de capital
Económica	capital-loss	Pérdidas de capital
Laboral	hours-per-week	Horas trabajadas semanalmente
Geográfica	native-country	País de origen

OBJETIVO income Ingreso anual (≤50K / >50K)



VARIABLE ESPECIAL: fnlwgt

No es salario, ni patrimonio, ni número de
empleados. Es el peso final censal.
Cada registro representa estadísticamente
a cierta cantidad de personas similares.
Debemos analizar si debe usarse como predictor
o su rol es solo de ponderación.



POSIBLE REDUNDANCIA

education (categórica) y education-num (numérica)
representan esencialmente lo mismo.
¿Necesitamos ambas? Lo definiremos con EDA
y metodología.



DATOS FALTANTES

Los faltantes originales aparecen como "?".
Especialmente en: workclass, occupation,
native-country.
Primero entender: ¿cuántos, dónde y por qué?
Luego decidir: ¿imputar, categorizar o eliminar?



VARIABLES SENSIBLES

Sexo, raza, edad y país de origen pueden introducir
sesgos en el modelo.
Debemos evaluar no solo desempeño global,
sino también equidad entre grupos.
Oportunidad para análisis de fairness.

5. PREGUNTAS DE NEGOCIO (EVOLUCIÓN)

NIVEL 1 DESCRIPTIVO



¿Cómo se distribuyen
los ingresos y qué
características presenta
la población analizada?

Enfoque: BI / Exploración

NIVEL 2 DIAGNÓSTICO



¿Qué características
parecen estar más
asociadas con ingresos
superiores a US\$50K?

Enfoque: Análisis de patrones

NIVEL 3 PREDICTIVO



¿Podemos predecir, a partir
de las características
disponibles, si una persona
tiene ingresos > US\$50K?

Enfoque: Machine Learning



6. ¿PARA QUÉ PUEDE SERVIR? (POSIBLES USOS)



Segmentación
socioeconómica



Investigación de
patrones de ingreso



Análisis de
desigualdades



Planificación de
políticas públicas



Estudios laborales
y educativos



Aún no definimos el uso final según la rúbrica del proyecto.
Primero entender el problema y los datos.

7. MAPA MENTAL DEL PROYECTO



8. CICLO DE ML (DE PUNTA A PUNTA)

- 1 Conocer el problema
- 2 Comprender los datos
- 3 EDA exploratorio
- 4 Preparar datos
- 5 Separar Train / Test
- 6 Construir pipeline
- 7 Transformar categóricas
- 8 Entrenar modelos
- 9 Validación cruzada
- 10 Comparar modelos
- 11 Ajustar hiperparámetros
- 12 Evaluar Test
- 13 Interpretar resultados
- 14 Desplegar (API / Interfaz)



NUESTRO EQUIPO

GI (coordinación y análisis)
Naomy (mejor estudiante de la clase)
Delay (nueva integrante, perfil muy bueno)



REGLA DE ORO

No escribir código que
no sepamos explicar
para qué sirve.



PRÓXIMO PASO

Abrir los 48.842 registros y 15 columnas reales,
hacer la primera radiografía del dataset y comenzar
el EDA entendiendo cada hallazgo desde el negocio
antes de limpiar absolutamente nada.



1994: EL MUNDO Y EE.UU. EN UN MOMENTO CLAVE

El contexto que da vida al Adult Dataset (Censo de 1994)

Este dataset es una fotografía de la sociedad, la economía y el mercado laboral de EE.UU. hace casi 30 años.

No es solo información antigua: es contexto, estructura y patrones de una época.



EE.UU. EN 1994: REALIDAD ECONÓMICA



Economía en recuperación

Luego de la recesión de 1990-1991, EE.UU. entraba en un ciclo de crecimiento.



Crecimiento del PIB: 4.0%

Uno de los más altos de la década.



Desempleo anual: 6.1%

Descendiendo desde el pico de 7.8% en 1992.



Ingreso mediano de hogares: US\$32,264

El umbral de US\$50,000 era ~55% superior a la mediana.



Desigualdad de ingresos

El quintil superior recibía 49.1% del ingreso total de los hogares.



Pobreza: 14.5%

17.1 millones de personas vivían por debajo del umbral de pobreza.

MERCADO LABORAL EN 1994



Sector servicios en expansión

Finanzas, seguros, salud, educación y servicios profesionales lideraban la creación de empleo.



Horas trabajadas

La jornada típica rondaba entre 35 y 40 horas semanales.



Empleo asalariado predominante

El trabajo por cuenta propia aún era minoría en la población.



Ocupaciones clave del momento

Administración, ventas, manufactura, transporte, educación, salud y oficios técnicos.



La educación importaba más

Las personas con educación universitaria tenían mayor probabilidad de superar los US\$50K.

EL MUNDO EN 1994



Globalización en aceleración

Caída del Muro de Berlín (1989) y fin de la Guerra Fría abrieron una nueva era económica.



NAFTA entra en vigor

El 1 de enero de 1994 nace el TLCAN (EE.UU., Canadá y México), impulsando el comercio regional.



Revolución tecnológica recién comenzando

Internet era incipiente y solo accesible para instituciones, universidades y empresas grandes.



Demografía en transición

Baby Boomers en su peak laboral (30-50 años), generaciones X y Millennials comenzaban a integrarse al mercado.

TECNOLOGÍA Y ACCESO A LA INFORMACIÓN: 1994 vs HOY



1994

- El sitio web del Census Bureau se lanzó en marzo de 1994.
- Internet no era masivo.
- No existían redes sociales.
- Los datos se consultaban en papel, CD-ROM o bases locales.

VS.



HOY

- Datos en la nube, en tiempo real y con gran granularidad.
- Algoritmos complejos y aprendizaje automático avanzado.
- Conectividad global y digitalización total de procesos.

¿POR QUÉ ES IMPORTANTE ESTE DATASET?



1. REFLEJA PATRONES REALES DE LA ÉPOCA

Captura relaciones entre educación, trabajo, horas, ocupación, edad, capital y origen, en una estructura económica determinada.



2. PERMITE ENTENDER DESIGUALDADES

Nos ayuda a analizar brechas de ingreso por sexo, raza, educación y ocupación en un contexto específico.



3. IDEAL PARA APRENDER ML DE PUNTA A PUNTA

Es un problema clásico de clasificación binaria con variables categóricas y numéricas, valores faltantes y desbalance de clases.



4. BASE DE ESTUDIOS E INVESTIGACIONES

Ha sido utilizado en miles de investigaciones sobre machine learning, economía, sociología y fairness (equidad algorítmica).



5. ENSEÑA A NO EXTRAPOLAR SIN CRITERIO

Los patrones de 1994 no representan la realidad actual. Esto nos recuerda la importancia del contexto temporal.

¿QUÉ SIGNIFICABA GANAR MÁS DE US\$50,000 EN 1994?

- Estabas en el ~24% superior de los ingresos (solo 1 de cada 4 personas).
- Permitía un nivel de vida cómodo para una familia promedio:



Comprar vivienda en muchas zonas suburbanas.



Tener 1 o 2 autos familiares.



Acceso pleno a educación superior para los hijos.



Viajes nacionales y algunos internacionales.



Capacidad de ahorro e inversión moderada.

Poder adquisitivo (referencia aproximada)

US\$50,000 en 1994 ≈ US\$110,000 – US\$115,000 en 2024 (ajustado por inflación acumulada)

Es decir, el umbral del dataset representa hoy un nivel de ingreso significativamente más alto.



¿QUÉ ENCONTRAREMOS EN ESTE DATASET?



Adultos (> 16 años) con actividad económica.



Información demográfica, laboral, educativa y económica.



Patrones asociados con ingresos ≤\$50K y >\$50K.



Desbalance de clases: 76% ≤\$50K vs 24% >\$50K.



Datos con valores faltantes y categorías variadas.



LO QUE DEBEMOS TENER SIEMPRE PRESENTE

- No es un reflejo de la realidad actual: es 1994.
- Contiene sesgos históricos y sociales de su tiempo.
- Debemos evaluar el desempeño del modelo con métricas adecuadas (no solo accuracy).
- Es fundamental analizar equidad entre grupos (sexo, raza, edad, país de origen, etc.).



Este dataset no solo nos enseña a predecir ingresos: nos enseña a entender personas, patrones y contextos reales de una época específica.

3er CANVAS DE CONTEXTO Y REALIDAD

¿POR QUÉ ESTUDIAMOS UN DATASET DE 1994 EN 2026?



Proyecto ML:
Predecir ingreso
mayor a US\$50K



Estudiamos el Adult Dataset (Censo de 1994) no para describir el mundo actual, sino para **aprender a construir, evaluar e interpretar modelos de Machine Learning** de punta a punta, entendiendo que todo modelo está condicionado por los datos, la población y el momento histórico del que aprende.

1. ¿QUÉ NOS ENSEÑA ESTE DATASET?



Es un "laboratorio" clásico y muy documentado de ML.



Contiene todos los desafíos reales que veremos en proyectos del mundo empresarial.



Nos permite aplicar TODO el ciclo de ML de punta a punta.



Ha sido estudiado por miles de investigaciones: podemos comparar y aprender de la evidencia previa.



Su estructura simple (pero rica) facilita enfocarnos en lo importante: metodología, decisiones e interpretación.

2. ¿POR QUÉ SIGUE SIENDO RELEVANTE HOY?

Lo que encontramos en 1994

Lo que aprendemos para ML en 2026



Variables numéricas y categóricas



Preparación y transformación de datos



Datos faltantes ("?"")



Tratamiento de faltantes e imputación



education / education-num



Redundancia, multicolinealidad y selección de variables



Clase >50K minoritaria (~24%)



Desbalance de clases, métricas adecuadas, umbrales



Sexo, raza, edad, origen



Sesgos, equidad (fairness) y análisis por grupos



14 predictores variados



Feature engineering, selección y importancia de variables



≤50K / >50K (Clasificación binaria)



Modelado supervisado, métricas y evaluación



Train y Test separados



Generalización, validación, evitar sobreajuste



Datos históricos (1994)



Concept drift (cambio temporal) y limitaciones de extrapolación

3. ¿QUÉ NO DEBEMOS OLVIDAR?



Los US\$50K son de 1994 (no equivalen a los de hoy).

El umbral tenía un poder adquisitivo mucho mayor.



El modelo aprende patrones de esa época y población.

No aprende "la verdad universal" sobre ingresos.



Buen desempeño histórico ≠ buen desempeño futuro.

Las relaciones entre variables e ingreso cambian con el tiempo.



No generalizar sin criterio.

Los patrones de 1994 pueden no representar la realidad actual (2026) por cambios económicos, sociales y tecnológicos.



Asociación ≠ Causalidad.

Encontraremos relaciones que ayudan a predecir, pero no implican causa directa.

4. NUESTRO "CONTRATO DEL PROBLEMA" ANTES DE TOCAR EL DATASET

1

Unidad de análisis

Cada persona adulta incluida bajo las condiciones de extracción del censo de 1994.



Qué conocemos (X)

14 características: educación, trabajo, ocupación, horas, capital, familia, demografía, origen, etc.



Qué queremos predecir (Y)

Si el ingreso anual de la persona es ≤ US\$50K o > US\$50K.



Momento de la predicción

Conocemos las X, pero aún NO conocemos la categoría de ingreso.



Errores que importan

Falso Negativo: Real >50K y predice ≤50K
Falso Positivo: Real ≤50K y predice >50K
¿Cuál es más grave? (Depende del uso)



Contra qué competimos

Modelo tonto que siempre predice ≤50K tiene ~76% de accuracy.

Nuestro modelo debe aportar valor real.



Qué es un "buen modelo"

No solo accuracy. Buscamos:
• Generalización
• Identificar >50K
• Consistencia
• Interpretabilidad
• Ausencia de sesgos preocupantes



Qué NO podrá afirmar el modelo

No establece causas. Solo identifica patrones asociados en los datos de 1994.

5. HIPÓTESIS INICIALES (ANTES DE VER LOS DATOS)

No para confirmarlas, sino para que los datos las confirmen, contradigan o matizen.



H1. Educación

A mayor nivel educativo, mayor probabilidad de ingresos >50K.



H2. Edad / Experiencia

La relación con ingreso probablemente no será lineal, existen etapas de mayor capacidad de ingreso.



H3. Ocupación y tipo de trabajo

Esperamos diferencias importantes entre categorías laborales y ocupaciones.



H4. Horas trabajadas

Podrían asociarse con mayores ingresos, pero no explicarán por sí solas pertenecer a >50K.



No buscamos demostrar que nuestras hipótesis son correctas. Buscamos descubrir qué dicen los datos.

6. ACUERDOS DEL EQUIPO ANTES DE EMPEZAR



Exploraremos los datos sin suposiciones ni conclusiones anticipadas.



Separaremos siempre: Dato (hecho) | Hallazgo (patrón) | Interpretación (significado).



Evitaremos data leakage: usaremos solo información disponible al momento de la predicción.



Evaluaremos el modelo de forma integral y justa, considerando el desbalance de clases y posibles sesgos.



Documentaremos decisiones, supuestos y limitaciones.



★ IDEA CLAVE: "No estudiamos 1994 para predecir 2026. Estudiamos 1994 para aprender a construir mejores modelos en 2026."